

# lab2

## 实验目的

使用卷积神经网络在CIFAR-10数据集上进行图像分类

## 实验内容

### 1.代码框架

1. utils.py: 工具函数包
2. model.py: 模型定义
3. train.py: 训练脚本,并在验证集上评估模型性能
4. eval.py: 在测试集上评估模型性能
5. accelerate\_config.yaml: 配置文件

### 2.网络结构

总体结构为:

Conv\_in -> n\*ResnetBlock -> FC -> Dropout -> FC -> Output

在前两个ResnetBlock后使用了MaxPooling层,其中ResnetBlock定义如下:

```
class ResnetBlock(nn.Module):
    """
    Residual block with group normalization, SiLU activation, and dropout.

    Args:
        - in_channels: number of input channels
        - out_channels: number of output channels
        - norm_groups: number of groups for group normalization
        - dropout_prob: dropout probability

    Inputs:
        - x: input tensor of shape (B, C, H, W)

    Outputs:
        - output tensor of shape (B, out_channels, H, W)
    """
    def __init__(self,
                 in_channels: int,
                 out_channels: int,
                 norm_groups: int,
                 dropout_prob: float,
                 ):
        super(ResnetBlock, self).__init__()
        self.net1 = nn.Sequential(
            nn.GroupNorm(norm_groups, in_channels),
            nn.SiLU(),
            nn.Dropout(dropout_prob),
            nn.Conv2d(in_channels, out_channels, kernel_size=3, stride=1, padding=1)
        )
        self.net2 = nn.Sequential(
            nn.GroupNorm(norm_groups, out_channels),
            nn.SiLU(),
            nn.Dropout(dropout_prob),
            nn.Conv2d(out_channels, out_channels, kernel_size=3, stride=1, padding=1)
        )
        if in_channels != out_channels:
            self.skip_conv = nn.Conv2d(in_channels, out_channels, kernel_size=1, stride=1)

    def forward(self, x):
        out = self.net1(x)
        out = self.net2(out)
        if hasattr(self, 'skip_conv'):
            x = self.skip_conv(x)
        return x + out
```

我最终选择的网络结构为:

Layer (type:depth-idx)	Input Shape	Output Shape	Param #
CNN	[1, 3, 32, 32]	[1, 10]	--
└─Conv2d: 1-1	[1, 3, 32, 32]	[1, 128, 32, 32]	3,584
└─ModuleList: 1-2	--	--	--
└─ResnetBlock: 2-1	[1, 128, 32, 32]	[1, 256, 32, 32]	--
└─Sequential: 3-1	[1, 128, 32, 32]	[1, 256, 32, 32]	--
└─GroupNorm: 4-1	[1, 128, 32, 32]	[1, 128, 32, 32]	256
└─SiLU: 4-2	[1, 128, 32, 32]	[1, 128, 32, 32]	--
└─Dropout: 4-3	[1, 128, 32, 32]	[1, 128, 32, 32]	--
└─Conv2d: 4-4	[1, 128, 32, 32]	[1, 256, 32, 32]	295,168
└─Sequential: 3-2	[1, 256, 32, 32]	[1, 256, 32, 32]	--
└─GroupNorm: 4-5	[1, 256, 32, 32]	[1, 256, 32, 32]	512
└─SiLU: 4-6	[1, 256, 32, 32]	[1, 256, 32, 32]	--
└─Dropout: 4-7	[1, 256, 32, 32]	[1, 256, 32, 32]	--
└─Conv2d: 4-8	[1, 256, 32, 32]	[1, 256, 32, 32]	590,080
└─Conv2d: 3-3	[1, 128, 32, 32]	[1, 256, 32, 32]	33,024
└─MaxPool2d: 2-2	[1, 256, 32, 32]	[1, 256, 16, 16]	--
└─ResnetBlock: 2-3	[1, 256, 16, 16]	[1, 512, 16, 16]	--
└─Sequential: 3-4	[1, 256, 16, 16]	[1, 512, 16, 16]	--
└─GroupNorm: 4-9	[1, 256, 16, 16]	[1, 256, 16, 16]	512
└─SiLU: 4-10	[1, 256, 16, 16]	[1, 256, 16, 16]	--
└─Dropout: 4-11	[1, 256, 16, 16]	[1, 256, 16, 16]	--
└─Conv2d: 4-12	[1, 256, 16, 16]	[1, 512, 16, 16]	1,180,160
└─Sequential: 3-5	[1, 512, 16, 16]	[1, 512, 16, 16]	--
└─GroupNorm: 4-13	[1, 512, 16, 16]	[1, 512, 16, 16]	1,024
└─SiLU: 4-14	[1, 512, 16, 16]	[1, 512, 16, 16]	--
└─Dropout: 4-15	[1, 512, 16, 16]	[1, 512, 16, 16]	--
└─Conv2d: 4-16	[1, 512, 16, 16]	[1, 512, 16, 16]	2,359,808
└─Conv2d: 3-6	[1, 256, 16, 16]	[1, 512, 16, 16]	131,584
└─MaxPool2d: 2-4	[1, 512, 16, 16]	[1, 512, 8, 8]	--
└─ResnetBlock: 2-5	[1, 512, 8, 8]	[1, 1024, 8, 8]	--
└─Sequential: 3-7	[1, 512, 8, 8]	[1, 1024, 8, 8]	--
└─GroupNorm: 4-17	[1, 512, 8, 8]	[1, 512, 8, 8]	1,024
└─SiLU: 4-18	[1, 512, 8, 8]	[1, 512, 8, 8]	--
└─Dropout: 4-19	[1, 512, 8, 8]	[1, 512, 8, 8]	--
└─Conv2d: 4-20	[1, 512, 8, 8]	[1, 1024, 8, 8]	4,719,616
└─Sequential: 3-8	[1, 1024, 8, 8]	[1, 1024, 8, 8]	--
└─GroupNorm: 4-21	[1, 1024, 8, 8]	[1, 1024, 8, 8]	2,048
└─SiLU: 4-22	[1, 1024, 8, 8]	[1, 1024, 8, 8]	--
└─Dropout: 4-23	[1, 1024, 8, 8]	[1, 1024, 8, 8]	--
└─Conv2d: 4-24	[1, 1024, 8, 8]	[1, 1024, 8, 8]	9,438,208
└─Conv2d: 3-9	[1, 512, 8, 8]	[1, 1024, 8, 8]	525,312
└─Flatten: 1-3	[1, 1024, 8, 8]	[1, 65536]	--
└─Linear: 1-4	[1, 65536]	[1, 512]	33,554,944
└─SiLU: 1-5	[1, 512]	[1, 512]	--
└─Dropout: 1-6	[1, 512]	[1, 512]	--
└─Linear: 1-7	[1, 512]	[1, 10]	5,130

### 3.训练策略

1. 首先读取配置文件,并设置随机种子,根据配置文件初始化模型
2. 使用`print_model_summary`函数打印模型结构
3. 读取数据集,按4:1的比例划分训练集和验证集
4. 把所需参数和配置文件导入`Trainer`类,损失函数为`CrossEntropyLoss`,优化器为`Adam`
5. 训练完成后加载`Evaluator`类,评估模型在验证集上的性能
6. 选择一组合适的超参数

### 4.评估策略

1. 读取配置文件,并设置随机种子,根据配置文件初始化模型
2. 读取数据集,使用CIFAR-10自己划分的训练集和测试集
3. 把所需参数和配置文件导入`Trainer`类,这次把训练集和验证集都用于训练
4. 训练完成后在测试集上评估模型的性能,并画出拟合的曲线与真实曲线的比较

### 5.Utils工具包介绍

我在`utils.py`中预先写好了一些工具函数,在这里列出它们的作用:

1. `class TrainConfig`: 用于加载训练参数配置
2. `print_model_summary()`: 打印网络结构并估计需要的显存
3. `make_dataloader()`: 从数据集中创建数据加载器
4. `cycle()`: 用于循环迭代器
5. `maybe_unpack_batch()`: 用于解包批次数据
6. `make_cifar()`: 用于创建CIFAR-10数据集
7. `get_date_str()`: 用于记录评估时间
8. `handle_results_path()`: 处理结果路径,如果不存在则创建
9. `zero_init()`: 零初始化
10. `init_config_from_args()`: 从命令行初始化配置文件
11. `init_logger()`: 初始化记录器
12. `log()`: 记录器

## 实验步骤

### 1.环境配置

安装依赖

```
conda create -n pytorch python=3.9
pip install -r requirements.txt
```

### 2.训练模型

配置文件:

```
compute_environment: LOCAL_MACHINE
distributed_type: NO
fp16: False
mixed_precision: no
num_processes: 1
gpu_ids: all
use_cpu: false
```

运行以默认参数配置开始训练:

```
accelerate launch --config_file accelerate_config.yaml train.py
```

或在Linux服务器上:

```
bash train.sh
```

### 3.评估模型

运行评估脚本

```
python eval.py
```

## 实验结果

在train.py中,我们能控制的超参数如下:

```
# Architecture
parser.add_argument("--in-channels", type=int, default=128)
parser.add_argument("--norm-groups", type=int, default=32)
parser.add_argument("--dropout-prob", type=float, default=0.5)
parser.add_argument("--n-resnet-blocks", type=int, default=3)

# Training
parser.add_argument("--batch-size", type=int, default=128)
parser.add_argument("--lr", type=float, default=2e-4)
parser.add_argument("--seed", type=int, default=123)


parser.add_argument("--results-path", type=str, default=None)
parser.add_argument("--epochs", type=int, default=10)
```

除去seed和results-path外,我们对其他参数进行了调整,分析如下:


1. in-channels: 输入通道数,默认为128,因为CIFAR-10的图像是彩色图像,我们希望选择一个较大的通道数,以便提取更多的特征,当in-channels为较小时,模型性能有显著下降
2. norm-groups: 组归一化的组数,默认为32,组归一化是一种归一化方法,它将通道分为若干组,每组进行归一化,这样可以减少模型的过拟合,提高模型的泛化能力,刚开始我选择的是8,但模型性能不佳,考虑到彩色图像的通道数较多,我选择了32,取得了不错的效果
3. dropout-prob: dropout概率,默认为0.5,dropout是一种正则化方法,可以减少模型的过拟合,提高模型的泛化能力,我选择了0.5,因为这是一个较为常用的值,在实验中取得了不错的效果

4. `n-resnet-blocks`: ResnetBlock的数量,默认为3,当不使用ResnetBlock,只使用两个卷积层时,模型在验证集上只有72%的准确率,使用两层ResnetBlock时,模型在验证集上的准确率达到81%,三层时达到了83%,再多时准确率没有显著提高,但是参数量过大,因此我选择了3层
5. `batch-size`: 批次大小,默认为128,考虑到我的设备显存较大,我使用了256,这样可以加快训练速度
6. `lr`: 学习率,默认为 $2e-4$ ,我选择了这个学习率,因为根据我之前处理CIFAR-10数据集的经验,这个学习率搭配128~256的批次大小效果较好
7. `epochs`: 训练轮数,默认为10,我选择了30,超过30时模型在验证集上的loss开始上升,说明模型开始过拟合


下面给出几次实验的结果:



1. 只使用两层卷积,无ResnetBlock,准确率为72%



2. 使用两层ResnetBlock,准确率为81%



3. 使用三层ResnetBlock,准确率为83%

最终结果,在测试集上选择参数:

```
batch_size: 256
dropout_prob: 0.5
epochs: 30
in_channels: 128
lr: 0.0002
n_resnet_blocks: 3
norm_groups: 32
results_path: results/test3/
seed: 123
```

```
11826 Loss: 0.1948: 100%|██████████| 5875/5880 [46:52<00:02, 1.99it/s]
11827 Loss: 0.2004: 100%|██████████| 5875/5880 [46:53<00:02, 1.99it/s]
11828 Loss: 0.2004: 100%|██████████| 5876/5880 [46:53<00:01, 2.02it/s]
11829 Loss: 0.2386: 100%|██████████| 5876/5880 [46:53<00:01, 2.02it/s]
11830 Loss: 0.2386: 100%|██████████| 5877/5880 [46:53<00:01, 2.05it/s]
11831 Loss: 0.1564: 100%|██████████| 5877/5880 [46:54<00:01, 2.05it/s]
11832 Loss: 0.1564: 100%|██████████| 5878/5880 [46:54<00:00, 2.06it/s]
11833 Loss: 0.2597: 100%|██████████| 5878/5880 [46:54<00:00, 2.06it/s]
11834 Loss: 0.2597: 100%|██████████| 5879/5880 [46:54<00:00, 2.08it/s]
11835 Loss: 0.2301: 100%|██████████| 5879/5880 [46:54<00:00, 2.08it/s]
11836 Loss: 0.2301: 100%|██████████| 5880/5880 [46:54<00:00, 2.57it/s]
11837 Loss: 0.2301: 100%|██████████| 5880/5880 [46:54<00:00, 2.09it/s]
11838 Saved model to results/test3/model.pt
11839 Results will be saved to 'results/test3'
11840 Accuracy: 0.8527
11841 Loss: 0.6370
```